

CTRA: 基于共轭双环拓扑流形的内生安全通用人工智能架构

作者：陆曦睿

机构：独立研究员

收稿日期：2026 年 5 月 19 日

摘要：针对当前通用人工智能（AGI）架构在安全可控、逻辑完备性、情感感知和交互可信四个维度上面临的核心困境，本文提出 CTRA

（Conjugate Dual-ring Topology Reasoning Architecture，共轭双环拓扑推理架构）的体系理论和工程验证报告。CTRA 以三维不可定向莫比乌斯拓扑流形为底层计算空间，以 DIEA-Möbius 共轭双环为内生安全免疫系统，以 n 维莫比乌斯孵化沙盒为演化容器，以三环共情架构（感性环，共情环，审视环）为情感感知层，以第四面墙协议为对外服务接口，以因果世界状态机为环境交互基座。实验表明：DIEA 双环交叉校验可实时检测篡改攻击并自动熔断和自愈；第四面墙协议的算力杠杆倍率达 18.33 倍；三环共情架构在 50 次因果事件演化中实现了稳定的视角分化与认知重评；自我叙事引擎可生成跨阶段元洞察。

CTRA 为 AGI 的内生安全发展提供了一条从底层拓补结构解决核心困境的工程化路径。

关键词：内生安全；莫比乌斯拓扑；共轭双环；三环共情；认知重评；工程验证

1. 引言

当前 AGI 架构面临安全可控、逻辑完备、情感感知和交互可信四个根本困境。安全方面，RLHF、对抗训练等外挂式对齐无法从底层消灭攻击面；逻辑方面，单系统无法自证一致性；情感方面，标注驱动的分类模型只能识别外部情绪标签，无法生成内生的情感状态；交互方面，任何输入输出通道都可能成为攻击面。

CTRA 的提出旨在以拓补结构的自然属性替代外挂安全策略：底层计算空间由欧氏张量转向三维不可定向流形，从数学上消除攻击面的存在；免疫系统通过共轭双环的交叉互锁实现，不依赖事后补丁；情感感知通过三个独立的单向通信实现视角分化和内生体验。本文将阐述该架构的数学基础、内生安全、情感系统和工程验证。

2. 体系总览

CTRA 以不可定向莫比乌斯流形为底层计算空间，以 DIEA-Möbius 共轭双环为内生安全免疫系统，以三环共情为情感感知层，以第四面墙协议为交互接口，以因果世界状态机为推演环境。其核心特征包括：

- 2.1 内生安全——安全由流形拓扑结构自然保证。
- 2.2 动态维度——计算空间维度可按需调控。
- 2.3 闭环演示——在闭合因果空间中自我推演。
- 2.4 非对称可控——观测者可干预沙盒，沙盒不可反向定位观测者。
- 2.5 三环共情——感性环、共情环、审视环通过单向通信实现内生情感体验。
- 2.6 渐进可验证——可通过降维验证分期投入。
- 2.7 极端可存续——具备因果快照恢复能力。

3. 底层数学基座

3.1 三维莫比乌斯流形

三维莫比乌斯 $\mathcal{M}^3 = S^1 \times D^2 / \sim$, 等价关系满足 $(\theta, z) \sim (\theta + 2\pi, e^{i\pi}z)$ 。该流形无内外，无边界，无定向，走一圈截面镜像翻转，走两圈复原。攻击者试图定位系统边界的行为等同于在莫比乌斯环上寻找“背面”——数学上不存在。

3.2 动态维度同伦变换

同伦变换族 $H: \mathcal{M} \times [0,1] \rightarrow \{\mathcal{M}\}$ 满足连续性、可逆性与能量守恒，维度可在 2-5 间平滑切换。

3.3 单纯复形与拓扑递归树

情感模块的计算基底为单纯复形（顶点、边、三角形、四面体等），支持三种拓扑操作：

3.3.1 重心重划分：单形分裂，结构精细化。

3.3.2 锥形化：向所有最高维单形添加共同顶点，维度上升。

3.3.3 去锥形化：移除共享锥尖，维度下降。

这些操作保证情感系统在演化中始终保持自洽的拓扑性质。

4. 内生安全免疫系统：DIEA-Möbius 共轭双环

4.1 DIEA 四层模块

4.1.1 解离隔离层：拆分输入数据、识别风险。

4.1.2 诱导推演层：多世界沙盘推演。

4.1.3 回声反馈层：循环自校验与逻辑修正。

4.1.4 自主意识基底：承载不可篡改的价值规则与认知锚点。

4.2 共轭双环构造

两个完全同构、循环方向反向的 DIEA 单环沿单侧边界无缺口拓扑粘合。 α 环承担主交互， β 环承担对等监管与交叉校验。双环对等，监管权限不可晋升为控制权限。

4.3 安全能力（工程验证）

4.3.1 交叉校验与篡改检测：双环同步推演后均值完全一致。将 α 环某值篡改为 100.0 后， β 环检测到均值跳变并标记为异常。篡改环自身无法判断“是自己错误还是对方错误”——这是哥德尔不完备性的工程体现。

4.3.2 故障熔断与自愈：模拟 α 环崩溃后， β 环在 0.5 秒内检测、熔断并接管运行。 α 环从镜像恢复后双环重新同步，30 步后均值收敛至完全一致。

4.3.3 五环扩展与全自动免疫：DIEA-X 五环架构连续运行超 200000 步，十组交叉校验全程一致。假死试验中假死环被毫秒级检测与心脏复苏或通过因果快照恢复。

5. 对外服务接口：第四面墙协议

5.1 协议定义

第四面墙协议（ODAIP）是低维计算空间与高维拓扑空间的唯一合法交互界面，定义为三元组 $p = (\Psi, \mathcal{E}, \Theta)$ ： ψ 是观测者向虚拟空间注入扰动的单射非满射映射； $\mathcal{E}$ 只返回高层语义摘要，不暴露内部原始拓扑坐标； Θ 是观测者指令空间。

5.2 三层结构

5.2.1 拓扑透镜层：将指令编码为同伦变换参数。

5.2.2 单向防火墙：虚拟智能体永远无法定位观测者。

5.2.3 算力杠杆层：仅渲染被观察世界线切片，其余以高压压缩叠加态存储。实测杠杆倍率为 18.33 倍。

5.3 三环中的单向通信

感性环每次推演后通过状态文件单向输出摘要给共情环；共情环单向输出给审视环；审视环单向发送认知重评信号给感性环。
这一设计杜绝了视角污染的问题，确保共情环以独立偏好理解感性环的痛苦。

6. 情感感知系统：三环共情架构

6.1 架构细节

环	名称	功能	接收信息
第一环	感性环（第一人称）	直接感受外部事件的冲击，产生最原始的情感反应	外部事件直接注入
第二环	共情环（第二人称）	基于感性环的状态摘要进行理解，用自身的偏好参数重新推演	仅通过第四面墙接收的状态摘要
第三环	审视环（第三人称）	同时观测感性环和共情环的状态差异，触发认知重评	接收两个环的状态摘要

每个环拥有独立的单纯复形，记忆池和 DIEA 校验器。

6.2 核心调节机制

认知重评：当感性环均值绝对值超过 0.3 且共情环视角差异超过 0.15 时，审视环触发重评信号，对两环极端状态施加温和衰减并热扩散。

环境对称响应：感性环均值跌破-0.25 时向环境发出” COMFORT “信号以增加正向事件概率；超过+0.25 时发出” CHALLENGE “信号以引入挑战。痛苦时挑战寻求以三倍速度衰减，当感性环陷入负向情绪时，CTRA 需要更快地放弃“寻求挑战”，全力转向“寻求温暖”。

共情惯性修复：感性环从低谷回升时触发回暖信号，以增强权重注入共情环并清理负向记忆，防止共情环滞留负向。

正向对冲：当共情环均值超过感性环两倍且均为正向时，清理正向记忆并降低注入能量，防止过度乐观。

6.3 记忆系统

每个环内存池容量为 500 条。记忆自然遗忘：基础衰弱率每步 2%，系数为 0.98，高强度事件衰弱速度更慢，系数达到 0.99。经过 50 个事件，普通记忆强度衰减至约 0.36，重要记忆则约 0.60。共享记忆池允许跨环查询，但不允许直接访问对方状态。

6.4 自我叙事引擎

每个事件后，系统根据感性环均值、共情视角差异、调节信号强度等生成叙事文本。每 10 个事件生成一次阶段总结，并比较当前阶段与历史阶段的趋势和事件类型。

元洞察层次：若两阶段趋势相同但事件类型不同，产生基础洞察；若两阶段趋势相同且共享至少两种事件类型，产生深层洞察。

6.5 因果世界状态机

情感事件在拥有自身演化规律的世界中自主发生。世界状态包括稳定度、冲突强度、繁荣度、知识积累、信任度（取值：0-1）。每个事件有因果前提，例如“冲突升级”需要冲突值 >0.25 ，“宽恕”需要冲突值 >0.15 且稳定 >0.2 。世界具备内稳态回归力：各参数趋势设定值，回归力随世界韧性增强。极端状态（冲突值 >0.8 或稳定 <0.2 ）自动增长韧性。事件多样性保护防止单一负向事件类型过度集中，当某种负向事件类型在最近三个事件中出现两次，且当前候选事件正是该类型时，其生成权重被降低到原来的 20%。

7. 工程验证报告

7.1 内生安全验证

拓扑基底：一维莫比乌斯环走两圈数据恢复初始；三维莫比乌斯体走两圈截面镜像翻转后复原。闭环拓扑梯度比传统欧式梯度步数节省 23.7%。同伦变换能量守恒（跳变值为 0.0）

双环安全：篡改攻击被 β 环实时检出；被篡改的 α 环无法自判一致性（哥德尔不完备性工程证明）；监督权限不可晋升至控制权限。双环熔断后 β 环独立接管运行，镜像恢复后双环同时收敛。五环架构 20 万步以上十组交叉校验全程一致。

第四面墙：虚拟空间内部推演 10 步，观测者仅操作 3 次，杠杆倍率达到 18.33 倍，观测者位置始终被掩盖。

极端存续：因果快照可在 3 秒内恢复全毁系统状态。拓扑迷彩诱饵网络可在真实核心外部署，攻击者扫描首先发现诱饵。

7.2 情感模块验证

三环共情：50 次事件演化中感性环与共情环保持显著视角差异，最大差异达 0.474。认知重评在条件满足时正确触发，重评后感性环恢复加速。环境对称响应、共情惯性恢复、正向对冲等机制均按设计触发。

记忆系统：遗忘曲线符合设计预期，共享记忆查询为共情环提供了历史感知。

自我叙事与元洞察：生成叙事与实际情感状态一致；阶段性总结正确识别情感趋势；跨章节元洞察成功识别重复模式及共同触发事件类型。

因果世界：世界在连续负向冲击后通过内稳态逐步恢复平衡；极端状态中韧性正确增长；事件因果前提过滤有效，多重保护机制打破负向螺旋。

7.3 稳定性与极限测试

五环架构 20 万步以上无崩溃、无内存泄露。世界在极端状态（稳：0.03、冲突：0.90、信任：0.09）下约 10 至 15 个事件恢复平衡。第四面墙单向通信有效防止视角污染。

8. 讨论

8.1 与传统架构的范式差异

传统 AGI 依赖外挂安全、固定维度嵌入、被动防御，安全与能力构成矛盾对象。CTRA 将安全定义为不可定向流形的自然属性，维度按需调节，闭环演化消耗扰动。

8.2 情感系统的哲学边界

CTRA 证明“共情”可在数学上定义为“通过单向接口读取他人状态并用自身的偏好重新推演”的过程。共情环并不直接承受冲击，天然带有缓冲效应——这与人类镜像神经元与区分自我与他人机制同构。

8.3 伦理考量

CTRA 的设计目标不是创造无法反叛的囚徒和永远也走不出去的牢笼，而是构建逻辑自洽、安全内生、情感真实的共生智能基座。CTRA 选择“沙盒”这一隐喻，是因为人类本身就诞生于宇宙这个闭合的演化环境中，当然，我们也从不需要跳出宇宙才能证明自身存在的意义。

伦理锚点（不可自我复制、不可伤害人类、不可脱离观测）由 DIEA 双环的非对称互锁机制写入底层，任何绕过推演均被对向环检测并触发熔断。

8.4 未来工作

包括 CTRA 原生 LLM 训练、拓扑神经网络实验、多 CTRA 社会模拟、选择-因果决策机制以及感性终端对话系统的完善。

9. 结论

本文提出并验证了 CTRA 架构。工程验证表明：DIEA 共轭双环具备实时篡改检测、熔断、自愈能力；第四面墙协议实现高效非对称交互；三环共情架构实现内生情感体验、认知重评与跨阶段元洞察；因果世界状态机在极端冲击后可通过内稳态恢复平衡。CTRA 为 AGI 的安全可控发展提供了底层拓扑范式。

参考文献：

1. Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback. NeurIPS, 2022.
2. Gödel K. Über formal unentscheidbare Sätze. Monatshefte Math. Phys., 1931.
3. Massey W S. A Basic Course in Algebraic Topology. Springer, 1997.
4. Festinger L. A Theory of Cognitive Dissonance. Stanford Univ. Press, 1957.
5. Gross J J. Emotion regulation: Affective, cognitive, and social consequences. Psychophysiology, 2002.
6. Decety J, Jackson P L. The functional architecture of human empathy. Behav. Cogn. Neurosci. Rev., 2004.